

Resumen del Proceso

Carga y Exploración Inicial

Cargué el dataset de "MKT BANCO PORTUGAL" y realicé una exploración inicial que incluyó revisar el tamaño, analizar gráficos, revisar los tipos de datos y las estadísticas descriptivas de las variables numéricas y categóricas. Identifiqué la presencia de valores atípicos, especialmente en la variable 'balance'.

Preparación de Datos para Clustering

Selecione un subconjunto de variables demográficas y financieras para la segmentación (subjetivo), eliminando aquellas relacionadas con resultados de campañas anteriores. Convertí las variables categóricas a formatos numéricos utilizando One-Hot Encoding y Ordinal Encoding.

Escalado de Datos

Apliqué StandardScaler y RobustScaler a las variables numéricas para mitigar el impacto de los valores atípicos y preparar los datos para el algoritmo K-Means. Concluí que RobustScaler era más adecuado debido a la presencia de outliers.

Determinación del Número Óptimo de Clusters (K)

Utilicé el método del codo y el coeficiente de silueta para determinar el número óptimo de clusters. Observé que el método del codo no era concluyente o que mi subjetividad no "me permitía" identificar el valor óptimo, mientras que el coeficiente de silueta sugería inicialmente K=2 con RobustScaler. Sin embargo, basándome en la lógica de negocio (donde más de dos segmentos de clientes tiene más sentido para estrategias de marketing), decidí explorar también **K=3**.

Aplicación del Modelo K-Means

Apliqué el algoritmo K-Means con K=2 y K=3, utilizando los datos escalados con RobustScaler, ya que esta versión me daba mejores resultados en cuanto a la silueta.

Análisis y Evaluación de los Clusters

Para ambos valores de K, analicé la composición de los clusters en términos de variables numéricas y categóricas, y evalué la calidad del clustering mediante la puntuación de silueta, el índice de Calinski-Harabasz y el índice de Davies-Bouldin. La visualización 3D me permitió observar la separación de los clusters en función de la edad, el balance y el nivel educativo. Lo cual sería una aproximación a la realidad, ya que son muchas variables/dimensiones para poder realizar un gráfico entendible.

Análisis de Silueta Detallado

Realicé un análisis profundo de la distribución de la puntuación de silueta individual para entender qué tan bien se agrupan los puntos dentro de cada cluster y cuán separados están de otros clusters. Confirmé que el clustering con K=2 tenía una silueta promedio significativamente más alta que con K=3, lo que indica una mejor separación general, aunque el Cluster 0 en K=2 presentaba una silueta baja (todos los puntos por debajo del promedio). Para K=3, la silueta promedio fue menor, y aunque algunos puntos estaban por

encima del promedio en cada cluster, la proporción era menor que en $K=2$, con lo cual podría decirse que fue una buena decisión inclinarme por 3 clusters..

Exploración de PCA

Intenté reducir la dimensionalidad con PCA a modo de curiosidad para ver como resultaban las métricas, pero concluí que no mejoraba significativamente la métrica de silueta para $K=2$ o $K=3$.

Conclusiones

Calidad del Clustering:

Las puntuaciones de silueta, aunque mejores con RobustScaler a comparación de StandardScaler (por la presencia de outliers), obtuvimos un buen resultado en $K = 2$, pero en reglas generales $K = 3$ no sería un buen resultado, lo cual sugiere que los datos pueden no tener una estructura de clusters esféricos perfectamente clara o que K-Means podría no ser el algoritmo ideal para capturar la complejidad de estos datos, especialmente con las variables categóricas codificadas. A nivel personal, teniendo en cuenta que el rango de la métrica va de -1 a 1, yo considero que 0.3891 esta bastante bien para el tipo de variables que manejamos y su conformación.

RobustScaler fue la Elección Correcta:

El análisis confirmó que RobustScaler fue más efectivo que StandardScaler debido a la presencia de outliers, resultando en mejores puntuaciones de silueta.

Interpretación de los Clusters con análisis de variables categóricas

Tasa de conversión: *porcentaje de clientes dentro de un segmento (cluster) que finalmente contrató el producto financiero (un depósito a plazo) que el banco estaba promocionando y fue el objeto de la variable etiqueta "y" del dataset, en este trabajo, puede tomarse como una variable para saber que tan afines o influenciados pueden ser nuestros clientes a nuestras campañas de marketing.*

Cluster 0: "Clientes de Alto Valor con Potencial de Conversión" (aprox. 13%)

- Perfil demográfico y financiero: Edad promedio de 43 años, balance significativamente superior al promedio general, con alta proporción de educación terciaria y ocupaciones de "management" o "retired".
- Comportamiento crediticio: Distribución equilibrada en hipotecas (50%) y menor proporción de préstamos personales (10.0%) versus el promedio general (15.3%).
- Estado civil: Similar al promedio, con 10.9% de divorciados.
- Respuesta a campañas: Tasa de éxito en campañas anteriores del 3.6%, ligeramente superior al promedio.

- Conversión: Presentan una tasa de conversión a depósito a plazo ligeramente superior al promedio general.
- Implicaciones estratégicas: Posible grupo ideal para estrategias de marketing personalizado y ofertas de valor diferenciado.

Cluster 1: "Base principal con alta actividad crediticia" (aprox. 85%)

- Perfil demográfico y financiero: Representa la mayoría de clientes, con edad y balance cercanos al promedio general. Predominio de educación secundaria y ocupaciones como "blue-collar", "services" y "technician".
- Comportamiento crediticio: Mayor proporción de hipotecas (57.8%) y préstamos personales (16.2%) que otros clusters y el promedio general.
- Estado civil: Mayor proporción de divorciados (12.0%).
- Respuesta a campañas: Baja tasa de éxito en campañas anteriores (2.7%).
- Conversión: Tasa de conversión ligeramente inferior al promedio.
- Implicaciones estratégicas: Segmento clave para productos crediticios básicos y estrategias de retención.

Cluster 2: "Clientes premium con baja propensión al producto" (aprox. 2%)

- Perfil demográfico y financiero: Grupo pequeño pero con el balance promedio más alto. Edad ligeramente superior y máxima proporción de educación terciaria y ocupaciones de "management" o "retired".
- Comportamiento crediticio: Distribución equilibrada en hipotecas (50%) y menor proporción de préstamos personales (8.6%).
- Estado civil: Notablemente más estable, con solo 2.9% de divorciados y 67.1% de casados.
- Respuesta a campañas: Mayor tasa de éxito en campañas anteriores (5.7%), duplicando casi el promedio general. Podríamos tomarlo de una manera similar a la tasa de conversión en este caso.
- Conversión: Menor tasa de conversión a depósito a plazo entre todos los clusters.
- Implicaciones estratégicas: Aunque responden bien a campañas, muestran bajo interés en el producto actual. Sugiero explorar productos de mayor valor o estrategias de upselling.

Conclusiones Integradas:

La incorporación de variables categóricas enriquece significativamente los perfiles, revelando que el Cluster 2 combina alto poder adquisitivo con estabilidad familiar y mejor respuesta histórica a campañas, mientras el Cluster 1 representa la base crediticia principal del banco. El Cluster 0 emerge como el segmento con mejor balance entre características demográficas favorables y propensión a la conversión. A mi parecer tomaría como grupos más interesantes al cluster 0 y 2 para poder “explotar”, ya que con el grupo 0 podría tener mayor facilidad de “llegar a ellos” con respecto al grupo 2, pero con este último podría tener mayor rentabilidad si lograra llegar a ese segmento, igualmente esto depende de las estrategias de marketing y de la organización.